
# PRÁCTICA Nº 2.7 Pig II



Nombre y apellidos: Alvaro Lucio-Villegas de Cea





# Índice

Ejemplo	3
Ejercicios	5
5 escritores más valorados.	5
10 escritores con más páginas.	7

2



# **Ejemplo**

- Descarga el archivo Eopinions.csv y proceso\_opiniones.pig.
- Ejecuta el script pig sobre el conjunto de datos.
  - -- 1.1 Fase de Extracción LOAD csv\_data = LOAD '/user/cloudera/pig/Eopinions.csv' USING PigStorage (',') as (class:chararray, opinion:chararray);
  - -- DUMP csv\_data; -- para comprobaciones
  - -- 1.2 Generar colección de comentarios (campo 1) comentarios = FOREACH csv\_data GENERATE \$1;
  - -- DUMP csv\_data; -- para comprobaciones
  - -- 2.1 Procesar cada comentario y trozearlo en palabras
  - -- TOKENIZE: cadena -> bolsa de palabras (bag of words)
  - -- FLATTEN: desanida/aplana tuplas bosas de palabras wordfile\_flat = FOREACH comentarios GENERATE FLATTEN (TOKENIZE(\$0)) as wordin;
  - -- 2.2 Agrupación por palabras (GROUP BY)
    wordfile\_grpd = GROUP wordfile\_flat by wordin;
  - -- 2.3 Calculo frecuencia de cada palabra word\_counts = FOREACH wordfile\_grpd GENERATE group, COUNT(wordfile\_flat.wordin) as cnt;
  - -- 2.4 Ordenación/Ranking de palabras por frecuencia word\_count\_des = ORDER word\_counts BY cnt DESC;
  - -- 3. Carga/almacenamiento STORE word\_count\_des into '/user/cloudera/pig/out';

3






# Ejecución del script.

```
[cloudera@quickstart ~]$ pig -f proceso opiniones.pig
log4j:WARN No appenders could be found for logger (org.apache.hadoop.util.Shell)
log4j:WARN Please initialize the log4j system properly.
log4j:WARN See http://logging.apache.org/log4j/1.2/faq.html#noconfig for more in
2023-04-21 07:41:59,961 [main] INFO org.apache.pig.Main - Apache Pig version 0.
12.0-cdh5.13.0 (rexported) compiled Oct 04 2017, 11:09:03
2023-04-21 07:41:59,961 [main] INFO org.apache.pig.Main - Logging error message
s to: /home/cloudera/pig 1682088119951.log
2023-04-21 07:42:00,658 [main] INFO org.apache.pig.impl.util.Utils - Default bo
otup file /home/cloudera/.pigbootup not found
2023-04-21 07:42:00,712 [main] INFO org.apache.hadoop.conf.Configuration.deprec
ation - mapred.job.tracker is deprecated. Instead, use mapreduce.jobtracker.addr
2023-04-21 07:42:00,712 [main] INFO org.apache.hadoop.conf.Configuration.deprec
ation - fs.default.name is deprecated. Instead, use fs.defaultFS
2023-04-21 07:42:00,712 [main] INFO org.apache.pig.backend.hadoop.executionengi
ne.HExecutionEngine - Connecting to hadoop file system at: hdfs://guickstart.clo
```

### Salida del comando

```
at org.apache.badoop.mapred.JobClient.getMapTaskReports(JobClient.java:667)
at org.apache.pig.backend.hadoop.exceutionengine.mapReduceLayer.MapReduceLauncher.java:150)
at org.apache.pig.backend.hadoop.exceutionengine.mapReduceLayer.MapReduceLauncher.java:150)
at org.apache.pig.Pischeror.LauncheTan(Pigerver.java:1334)
at org.apache.pig.PigServer.exceutcompil.ediogical(Plana(PigServer.java:1319)
at org.apache.pig.PigServer.exceutcompil.ediogical(Plana(PigServer.java:1319)
at org.apache.pig.PigServer.exceutceBatch(PigServer.java:1319)
at org.apache.pig.PigServer.exceutceBatch(PigServer.java:1387)
at org.apache.pig.PigServer.exceutceBatch(PigServer.java:1387)
at org.apache.pig.tools.grunt.GruntParser.parseStopomError(GruntParser.java:140)
at org.apache.pig.tools.grunt.GruntParser.parseStopomError(GruntParser.java:202)
at org.apache.pig.tools.grunt.GruntParser.parseStopomError(GruntParser.java:173)
at org.apache.pig.tools.grunt.GruntParser.parseStopomError(GruntParser.java:173)
at org.apache.pig.tools.grunt.GruntParser.parseStopomError(GruntParser.java:173)
at org.apache.pig.tools.grunt.GruntParser.parseStopomError(GruntParser.java:173)
at org.apache.pig.tools.grunt.GruntParser.parseStopomError(GruntParser.java:173)
at org.apache.pig.tools.grunt.GruntParser.parseStopomError(GruntParser.java:173)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethod)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethod)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethod)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethod)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethod)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethodAccessorimpl.java:27)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethodAccessorimpl.java:27)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethodAccessorimpl.java:27)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethodAccessorimpl.java:27)
at sun.reflect.NativeMethodAccessorimpl.invoke(NativeMethodAccessorimpl.java:27)
at sun.reflect.NativeMet
```

# Contenido del fichero en HDFS.



Nombre y Apellidos:Alvaro-Lucio-Villegas de Cea





# **Ejercicios**

- Descarga el archivo books.csv

#### 5 escritores más valorados.

- Almacena en un archivo el ranking con los 5 escritores mejor valorados

```
-- Carga el archivo de datos en una relación llamada 'books'
books = LOAD '/user/cloudera/pig/books.csv' USING PigStorage(';')
       AS (bookID:int, title:chararray, authors:chararray,
       average rating:float, isbn:chararray, isbn13:chararray,
       language code:chararray, num pages:int, ratings count:int,
       text reviews count:int, publication date:chararray,
publisher:chararray);
-- Agrupa los autores y calcula el promedio de sus valoraciones,
-- luego ordena los resultados de manera descendente según la valoración
promedio
author ratings = GROUP books BY authors;
top authors = FOREACH author ratings GENERATE group AS
author, AVG (books. average rating) AS avg rating;
sorted authors = ORDER top authors BY avg rating DESC;
-- Almacena los 5 mejores autores en un archivo
top five = LIMIT sorted authors 5;
STORE top five INTO '/user/cloudera/pig/TOPautores' USING PigStorage(',');
```






# CENTRO BILINGÜE INGLÉS

# Salida del script y contenido del fichero generado.

# Contenido del fichero en HDFS.



Nombre y Apellidos:Alvaro-Lucio-Villegas de Cea

Título de la práctica: Práctica 2.7. Pig II





7

# 10 escritores con más páginas.

- Almacena en un archivo el ranking con los 10 escritores con más páginas escritas.
- -- Carga el archivo de datos en una relación llamada 'books' books = LOAD '/user/cloudera/pig/books.csv' USING PigStorage(';') AS (bookID:int, title:chararray, authors:chararray, average\_rating:float, isbn:chararray, isbn13:chararray, language\_code:chararray, num\_pages:int, ratings\_count:int, text\_reviews\_count:int, publication\_date:chararray, publisher:chararray);
- --- Agrupa los autores y suma el número de páginas de todos sus libros author\_pages = GROUP books BY authors; total\_pages = FOREACH author\_pages GENERATE group AS author,SUM(books.num\_pages) AS total\_pages;
- -- Ordena los resultados de manera descendente según el número de páginas sorted\_authors = ORDER total\_pages BY total\_pages DESC;
- -- Almacena los 10 autores con más páginas escritas en un archivo top\_ten = LIMIT sorted\_authors 10; STORE top\_ten INTO '/user/cloudera/pig/TOPPaginas' USING PigStorage(',');

Nombre y Apellidos:Alvaro-Lucio-Villegas de Cea





# Salida del comando

Hadoopversion | Pigversion | Disprison | Disprison | Disprison | Cloudera | PinishedAt | Peatures | Pi

## Contenido del fichero en HDFS.



8

Título de la práctica: Práctica 2.7. Pig II